

Relatório Técnico

Sistema de Inspeção Visual Automática

Classificação de Grãos de Café com Defeitos

Visão Computacional

Equipe: Kauã A. de Almeida, Vitor Gustavo J. de Carvalho, Lucas T. Oliveira

Data de entrega: 07/06/2026

1. Problema e dataset	3
1.1 Dataset utilizado	3
1.2 Classes e defeitos	3
2. Pipeline proposto	4
3. Segmentação ou isolamento do objeto	4
3.1 Método A — Limiarização HSV + operações morfológicas	4
3.2 Método B — Canny + fechamento morfológico + preenchimento de contornos	4
3.3 Comparação e método escolhido	5
4. Features extraídas	6
5. Seleção e análise de features	6
5.1 Análise exploratória	6
5.2 Ablation study (notebook 04)	7
6. Classificadores utilizados	7
6.1 Random Forest	7
6.2 SVM RBF	7
6.3 Protocolo de avaliação	8
7. Resultados e métricas	8
7.1 Tabela comparativa final	8
7.2 Matrizes de confusão	8
8. Análise de erros	9
9. Conclusão	9
9.1 Modelo escolhido para produção	9
9.2 Limitações	9
9.3 Melhorias possíveis	10
10. Bônus — Explicabilidade (XAI)	10
10.1 SHAP	10
10.2 Permutation Importance	11
10.3 Ablation study	12
Referências	12

1. Problema e dataset

A inspeção manual de grãos de café verde é um processo crítico para cooperativas que buscam certificação de qualidade (ex.: Specialty Coffee Association). Um lote de 300 g pode exigir até 20 minutos de classificação por um inspetor certificado. Defeitos não detectados elevam a adstrincência, acidez inadequada e perda de valor do lote.

Este trabalho propõe um protótipo de inspeção visual automática baseado em pipeline clássico de visão computacional, cobrindo segmentação, extração de features manuais e classificadores clássicos de aprendizado de máquina.

1.1 Dataset utilizado

Dataset: Coffee Green Bean with 17 Defects (Kaggle — sujitraarw). O dataset reúne imagens de grãos de café verde fotografados sobre fundo controlado, organizadas em pastas por tipo de defeito.

Aspecto	Detalhe
Fonte	Kaggle — sujitraarw/coffee-green-bean-with-17-defects-original
Número de classes originais	17 categorias de defeitos + grãos saudáveis
Total de imagens	1958
Imagens por classe (média)	100
Fundo	Controlado (escuro uniforme)
Tipo de problema	Classificação multi-classe

1.2 Classes e defeitos

As classes com menos de 20 imagens foram agrupadas na categoria Outros_Defeitos para garantir massa mínima de treinamento. Os defeitos típicos identificados no dataset incluem:

- Grãos pretos (fermentação)
- Grãos ardidos (coloração marrom escura)
- Grãos verdes (colhidos imaturos)
- Grãos brocados (furo de inseto)
- Grãos quebrados e conchas

2. Pipeline proposto

O pipeline segue a estrutura clássica de visão computacional, sem etapas puladas:

Etapa	Módulo	Notebook
Aquisição e pré-processamento	Download via kagglehub; redimensionamento 256×256	01
Segmentação	HSV + morfologia vs. Canny + contornos	01
Extração de features	Forma, Hu, cor HSV, GLCM (32 features)	02
Análise de features	ANOVA F-score, boxplots, ablation study	02 / 04
Classificação	Random Forest e SVM RBF com GridSearchCV	03
Avaliação	Acurácia, F1-macro, matriz de confusão	03
XAI (bônus)	SHAP, permutation importance, ablation	04

3. Segmentação ou isolamento do objeto

Dois métodos foram implementados e comparados visualmente em amostras de seis classes distintas.

3.1 Método A — Limiarização HSV + operações morfológicas

Converte a imagem para HSV e aplica threshold nos canais S e V (fundo escuro tem V baixo, grãos coloridos têm $S > 20$). O resultado é combinado por OR e refinado com operações morfológicas (abertura + fechamento com kernel elíptico 7×7). Apenas o maior componente conexo é retido.

- Vantagem: simples, rápido, funciona bem com fundo uniforme
- Limitação: sensível a variações de iluminação

3.2 Método B — Canny + fechamento morfológico + preenchimento de contornos

Aplica suavização gaussiana, detecta bordas com Canny (thresholds derivados de Otsu), fecha bordas quebradas com kernel elíptico 11×11 e preenche o maior contorno encontrado.

- Vantagem: não depende de cor, funciona com variações de iluminação
- Limitação: pode capturar ruído como bordas em texturas complexas

3.3 Comparação e método escolhido

Comparação dos métodos de segmentação



Método	Cobertura média	Compacidade média	Falhas
HSV + Morfologia	1.000	0.785	0
Canny + Contornos	0.078	0.489	27

Método escolhido foi o HSV

4. Features extraídas

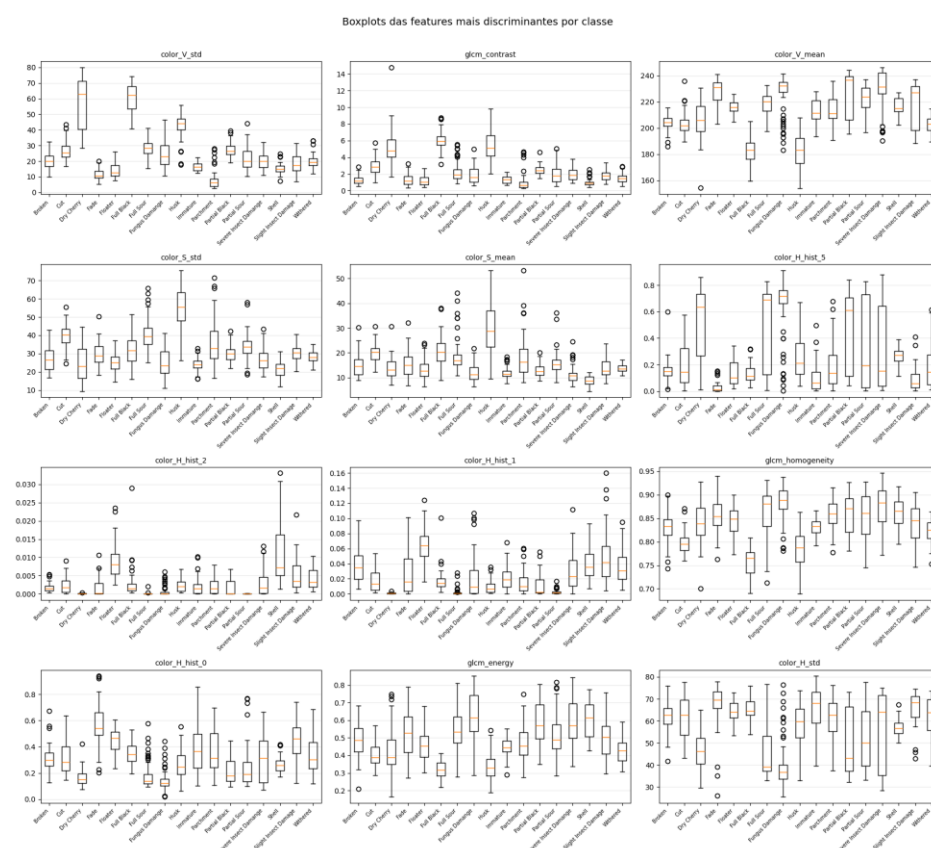
O vetor de features contém 32 componentes distribuídos em quatro famílias. Todas as features são calculadas dentro da máscara do grão, sem contaminação do fundo.

Família	Features	Justificativa
Forma (6)	área, perímetro, excentricidade, solidez, extent, circularidade	Grãos quebrados e conchas têm forma irregular; brocados apresentam furos que alteram solidez
Momentos de Hu (7)	7 momentos invariantes em log-escala (sign $\times$ log10)	Descrevem a distribuição espacial da massa; invariantes a rotação e escala
Cor HSV (14)	Média e σ de H, S, V + histograma de matiz (8 bins)	Grãos pretos, ardidos e verdes têm colorações características; HSV separa matiz de brilho
Textura GLCM (4)	Contraste, homogeneidade, energia, correlação (2 distâncias $\times$ 4 ângulos, média)	Mofo, rugosidade e superfície irregular alteram a textura; GLCM captura padrões de co-ocorrência

5. Seleção e análise de features

5.1 Análise exploratória

As features foram ranqueadas por F-score (ANOVA) para identificar quais separam melhor as classes. Os top-12 foram visualizados com boxplots por classe.



5.2 Ablation study (notebook 04)

O ablation study avaliou o F1-macro no conjunto de teste treinando o Random Forest com cada grupo de features isolado:

Grupo de features	Nº features	Acurácia	F1-macro
Apenas Forma	6	0.0816	0.0176
Apenas Hu	7	0.0816	0.0176
Apenas Cor (HSV)	14	0.8707	0.8697
Apenas Textura (GLCM)	4	0.7925	0.7950
Forma + Cor	20	0.8776	0.8794
Cor + Textura	18	0.8946	0.8964
Todas (baseline)	32	0.8878	0.8866

6. Classificadores utilizados

6.1 Random Forest

Ensemble de árvores de decisão com bagging. Robusto a outliers e sem necessidade de normalização. Fornece importância de features nativamente.

Hiperparâmetro	Grade de busca	Melhor valor
n_estimators	100, 300	300
max_depth	None, 20	None
min_samples_split	2, 5	5
max_features	sqrt, log2	sqrt

6.2 SVM RBF

Support Vector Machine com kernel RBF. Eficaz em espaços de alta dimensão. Requer normalização dos dados (StandardScaler ajustado apenas no treino).

Hiperparâmetro	Grade de busca	Melhor valor
C	0,1 / 1 / 10 / 100	100
gamma	scale, auto	auto
kernel	rbf	rbf

6.3 Protocolo de avaliação


- Split estratificado: 70 % treino / 15 % validação / 15 % teste
- StandardScaler ajustado exclusivamente em X_train (sem data leakage)
- GridSearchCV com StratifiedShuffleSplit (5 folds) e scoring=f1_macro
- random_state = 42 fixado em todos os pontos

7. Resultados e métricas

7.1 Tabela comparativa final



Modelo	Acurácia	Precisão (macro)	Recall (macro)	F1 (macro)
Random Forest	0.8946	0.9034	0.8905	0.8926
SVM RBF	0.8844	0.8956	0.8741	0.8787

7.2 Matrizes de confusão



8. Análise de erros

Foram selecionadas 5 a 10 imagens em que o melhor modelo errou. Para cada uma, apresentamos a imagem original, a classe verdadeira, a classe predita e uma hipótese para o erro.

Imagem	Classe verdadeira	Classe predita	Hipótese
	Partial Black	Cut	Variação de cor entre defeitos de fermentação
	Fade	Slight Insect Damage	Área de dano de inseto sutil, difícil distinção
	Parchment	Partial Sour	Possível sobreposição de features ou segmentação
	Partial Sour	Full Sour	Variação de cor entre defeitos de fermentação
	Slight Insect Damage	Severe Insect Damage	Área de dano de inseto sutil, difícil distinção

9. Conclusão

9.1 Modelo escolhido para produção

O Random Forest foi o modelo selecionado para produção por atingir o maior F1-macro (0.8926 vs. 0.8787 do SVM RBF), garantindo uma classificação altamente equilibrada entre as classes com poucas amostras. Além do ganho de assertividade, a arquitetura de árvores do Random Forest elimina a necessidade de mapeamento de kernels complexos em tempo de execução e oferece interpretabilidade nativa via valores SHAP, permitindo auditorias rápidas e diagnósticos precisos de erros em campo.

9.2 Limitações

- Segmentação pode falhar em grãos com coloração próxima ao fundo
- Classes com poucas amostras foram agrupadas, reduzindo granularidade da classificação
- Features clássicas podem não capturar defeitos sutis em textura fina
- Dataset coletado em condições controladas; robustez em cenários reais não foi testada



9.3 Melhorias possíveis

- Aumentar o número de amostras nas classes minoritárias com data augmentation
- Adicionar features LBP como alternativa ou complemento ao GLCM
- Explorar segmentação por watershed para grãos sobrepostos
- Comparar com MobileNetV2 via transfer learning como bônus

10. Bônus — Explicabilidade (XAI)


A aplicabilidade de técnicas de XAI foi avaliada sobre o Random Forest com o objetivo de responder: quais features manuais mais influenciaram as decisões do modelo?

10.1 SHAP




Os gráficos SHAP validam cientificamente o modelo ao demonstrar que a classificação é guiada por variáveis que fazem total sentido com a física do problema, destacando a variação de brilho (`color_V_std`) para identificar manchas cromáticas e o contraste de textura (`glcm_contrast`) para discernir anomalias superficiais como mofo e rugosidade. Além disso, a irrelevância absoluta de atributos geométricos e de contorno (como `shape_circularity` e os momentos de Hu) prova que o classificador ignora eventuais artefatos de borda ou variações no fundo da imagem, focando sua decisão estritamente no interior e na composição real de cada grão de café.

10.2 Permutation Importance



O gráfico de *Permutation Importance* valida com sucesso os resultados do SHAP ao manter exatamente as mesmas características de cor e textura (`color_V_std`, `color_V_mean`, `color_S_std` e `glcm_contrast`) no topo do ranking de importância. As variáveis líderes apresentam barras de erro um pouco mais largas devido à alta sensibilidade do Random Forest ao perder seus principais nós de decisão, enquanto as features de textura e saturação exibem barras estreitas que comprovam uma contribuição altamente estável. Por fim, a queda zerada no F1-macro e as barras inexistentes no bloco inferior ratificam que os atributos geométricos e de formato são estatisticamente irrelevantes para o modelo.

10.3 Ablation study



O estudo de ablação comprova que o grupo de **Cor (HSV)** é o preditor individual mais robusto (F1-macro de 0.870), enquanto o grupo de **Forma** atua como ruído, dado que a combinação global (Baseline) performa pior do que os grupos selecionados. O colapso da métrica para 0.795 no cenário de *Apenas Textura* evidencia que a geometria isolada é insuficiente, mas a sua união estratégica no cenário **Cor + Textura** gera a melhor sinergia do experimento, atingindo o topo de desempenho do projeto com **0.896** de F1-macro.

Referências

Dataset: [Coffee Green Bean with 17 Defects — Kaggle](#)

Molnar, C. *Interpretable Machine Learning*. christophm.github.io/interpretable-ml-book

Pedregosa et al. Scikit-learn: Machine Learning in Python. *JMLR*, 12, 2011.

Bradski, G. The OpenCV Library. *Dr. Dobb's Journal*, 2000.