



Sistema de Inspeção Visual Automática

Classificação de Grãos de Café com Defeitos

Visão Computacional · Cenário B

Vitor G. J. de Carvalho · Kauã A. de Almeida · Lucas T. de Oliveira

07 / 06 / 2026

O problema: inspeção manual de grãos de café

Por que automatizar?



Lenta

Até 20 min para
classificar 300 g



Cara

Inspetores certificados
em turnos de 8 h



Inconsistente

Taxa de erro cresce
com o cansaço



Subjetiva

Dois inspetores raramente
classificam igual



A visão computacional resolve esses quatro problemas simultaneamente

Dataset: Coffee Green Bean with 17 Defects

Kaggle · sujitraarw

Características

Fonte:	Kaggle — sujitraarw
Classes originais:	17 defeitos + saudáveis
Fundo:	Controlado (escuro uniforme)
Resolução:	256 × 256 px (redimensionado)
Tipo:	Classificação multi-classe
Grupos c/ < 20:	Agrupados em 'Outros_Defeitos'


Defeitos investigados

	Grãos pretos	fermentação avançada
	Grãos ardidos	marrom escuro intenso
	Grãos verdes	colhidos imaturos
	Grãos brocados	furo de inseto
	Quebrados/conchas	forma irregular
	Saudáveis	referência normal

💡 Fundo controlado facilita a segmentação; defeitos têm assinaturas de cor e textura bem distintas — pipeline clássico é suficiente.

Pipeline proposto

Cinco etapas encadeadas — nenhuma pulada



Bônus: 04_bonus_xai.ipynb — SHAP · Permutation Importance · Ablation Study

Segmentação: dois métodos comparados

Isolamento do grão do fundo controlado

Método A — Limiarização HSV + Morfologia

- Converte para HSV
- Threshold nos canais S e V
- Combina por OR (inclusivo)
- Abertura + fechamento (kernel 7×7)
- Mantém maior componente conexo

Método B — Canny + Contornos

- Escala de cinza + blur gaussiano
- Thresholds automáticos (Otsu)
- Detecta bordas com Canny
- Fechamento morfológico (11×11)
- Preenche o maior contorno

Critério	Método A (HSV)	Método B (Canny)
Velocidade	✓ Rápido	Médio
Dep. de cor	Sim (HSV)	✓ Não
Ruído	✓ Baixo	Texturas complexas
Escolhido	HSV Escolhido	

Extração de features manuais

32 features por grão · 4 famílias · todas dentro da máscara

Forma (6)

- Área (normalizada)
- Perímetro (normalizado)
- Excentricidade
- Solidez
- Extent
- Circularidade

Quebrados e conchas têm forma irregular; brocados alteram solidez

Momentos de Hu (7)

- 7 momentos invariantes
- Escala logarítmica
- $\text{sign} \times \log_{10}(|h| + \epsilon)$
- Invariantes a rotação e escala

Distribuição espacial da massa; independe de pose

Cor HSV (14)

- Média H, S, V
- Desvio-padrão H, S, V
- Histograma de matiz (8 bins)
- Calculado dentro da máscara

Pretos, ardidos e verdes têm colorações características

Textura GLCM (4+1)

- Contraste
- Homogeneidade
- Energia
- Correlação
- 2 dist. × 4 ângulos
- média sobre todas

Rugosidade e superfície irregular — mofo e casca danificada


Total: 32 features por grão

Análise e seleção de features

Quais realmente separam as classes?


Análise exploratória

- ANOVA F-score → ranking das 12 features mais discriminantes
- Boxplots por classe para visualizar separação



Ablation study (notebook 04)

Cada grupo treinado isoladamente:



Classificadores e protocolo de avaliação

Dois modelos clássicos com GridSearchCV

Random Forest

Ensemble de árvores robusto a outliers.
Importância de features nativa.

Hiperparâmetros testados:

n_estimators: 100, 300 → 300

max_depth: None, 20 → None

min_samples_split: 2, 5 → 5

max_features: sqrt, log2 → sqrt

SVM com kernel RBF

Eficaz em espaços de alta dimensão.
Requer normalização (StandardScaler).

Hiperparâmetros testados:

C: 0.1 / 1 / 10 / 100 → 100

gamma: scale, auto → auto

kernel: rbf → rbf


Protocolo de avaliação:

- ▶ Split estratificado 70 / 15 / 15 · random_state = 42
- ▶ StandardScaler ajustado APENAS em X_train (sem data leakage)
- ▶ GridSearchCV com StratifiedShuffleSplit (5 folds) · scoring = f1_macro

Resultados — tabela comparativa

Conjunto de teste (15% dos dados, usado uma única vez)

Modelo	Acurácia	Precisão macro	Recall macro	F1-macro
Random Forest	0.8946	0.9034	0.8905	0.8926
SVM RBF	0.8844	0.8956	0.8741	0.8787




F1 reportado como métrica principal
Dataset pode não ser perfeitamente balanceado

Acurácia sozinha pode enganar
Mascararia modelo que chuta classe majoritária

F1-macro pondera classes igualmente
Mais justo para classes com poucas amostras

Matriz de confusão — melhor modelo

Normalizada por classe verdadeira (linha)



Matriz de confusão normalizada

Leituras principais

Melhores classes

Classes com 1.0

Classe mais difícil

Partial Black (0.65)

Confusão principal

Pontos fora da diagonal principal com valor 0.2

Hipótese do erro

Partial Black vs. Cut

Partial Sour vs. Full Sour

Fade vs. Severe Insect Damage


Análise de erros e explicabilidade (XAI)

O modelo erra onde faz sentido?

Exemplos de erro do melhor modelo

Imagem	Real	Predito	Hipótese
	Partial Black	Cut	O grão apresenta uma mancha preta muito bem. O restante do grão mantém a coloração normal.
	Partial Sour	Full Sour	A transição abrupta entre a parte clara do grão e a mancha escura gera uma "borda" (gradiente de intensidade muito alto).
	Parchment	Partial Sour	Como a mancha escura fica na ponta e se mistura com o fundo (ou cria uma área de sombra)

SHAP — importância global



Interpretação SHAP:

- color_V_std*: Mede a variação interna de brilho no grão, sendo ideal para detectar manchas localizadas e quebras físicas.
- color_V_mean*: Avalia a claridade média geral da amostra, funcionando como um termômetro para separar grãos muito escuros (Full Black) dos muito claros.
- glcm_contrast*: Analisa a rugosidade e irregularidade da textura, servindo como o principal desempate para grãos que possuem cores muito semelhantes.
- color_H_hist_2*: Quantifica a presença de uma tonalidade de cor específica, isolando com precisão os tons de transição causados pela fermentação.



Conclusão

Modelo escolhido para produção

Random Forest · F1-macro = 0.8926 · Acurácia = 0.8946

- 01** F1-macro de 0.8926, garantindo uma vantagem de +1.39 p.p. acima do SVM RBF
- 02** Importância de features nativa → diagnóstico de falhas em campo
- 03** Baixo tempo de inferência → adequado para esteira em tempo real

Pipeline clássico com features manuais de cor e textura mostrou-se viável para separar defeitos de grãos de café sem redes neurais profundas.

Limitações do trabalho

Honestidade metodológica



Segmentação imperfeita

Grãos com coloração próxima ao fundo geram máscaras incompletas, impactando features de forma.



Classes agrupadas

Classes com < 20 imagens foram unidas em 'Outros_Defeitos', reduzindo granularidade.



Dataset controlado

Variações de iluminação e câmera em ambiente real exigiriam recalibração do pipeline.



Defeitos sutis

Features clássicas têm dificuldade quando a diferença visual entre classes é pequena.

Melhorias propostas:

- ▶ Data augmentation para classes minoritárias
- ▶ LBP como alternativa ao GLCM em texturas finas
- ▶ Comparação com MobileNetV2 via transfer learning

Obrigado!



Repositório GitHub:

https://github.com/CelebroPensante/VC_Coffee_Inspection

Dataset:

kaggle.com/datasets/sujitraarw/coffee-green-bean-with-17-defects-original

Equipe:

Vitor G. J. de Carvalho · Kauã A. de Almeida · Lucas T. de Oliveira